


Jev

Code Review • Sheriff

Bautista Sánchez

- / espacio avanzar
- ← retroceder
- f pantalla completa
- r repetir animación
- m audio del video

Slides 13, 24 y casos 18 a 22 tienen pasos extra: el primer
→ revela, no avanza. Slides 23 y 24 van en dark.



Portada: "Jev"

en pantalla

título Jev + "el modelo que no escribe ni una palabra".

qué decir

- Arranca con el gancho: "Esto salió hace unos días y me voló la cabeza. Es un modelo de IA que NO escribe texto. Ni una palabra. Y una vez que se entiende el motivo, te hace querer usarlo."
- Pon la expectativa: "A lo largo de los próximos minutos les voy a contar qué es, cómo funciona, cuánto cuesta, y, lo más importante, cuándo conviene usarlo y cuándo no."

siguiente 02 · El problema

El problema

en pantalla

LLMs = lentos + alucinan; barras de latencia/costo/alucinación.

qué decir

- Aterriza el dolor con algo nuestro: "Cuántas veces hemos querido solo clasificar algo, ¿este ticket es de billing o soporte?, ¿este documento es una factura?, y terminamos llamando a un LLM gigante, esperando segundos y pagando por un párrafo que después tenemos que parsear."
- Frase clave: "Para chatear son insuperables. Para **decidir**, son un cañón para matar una mosca."
- Transición: "De esa incomodidad exacta nace Jev."

siguiente

03 · Quién y por qué

Quién y por qué

en pantalla

TypeSafe AI, Diogo Almeida (ex-OpenAI), timeline, \$40M.

qué decir

- Da credibilidad: "Esto no es un experimento de fin de semana. El CEO, Diogo Almeida, estuvo ~4 años en OpenAI trabajando en las tripas de InstructGPT, ChatGPT y GPT-4."
- El insight fundacional: "Su observación fue: la IA ya chatea mejor que un humano, pero la **automatización de verdad** sigue rota. Estuvieron alrededor de 2 años en silencio resolviendo eso."
- Señala que hay respaldo fuerte (\$40M seed, DCVC, ~\$200M valuación) → "el mercado se lo está tomando en serio."

siguiente

04 · Qué es

Qué es

en pantalla

LLM devuelve un string vs. Jev devuelve valor tipado + prob + confianza.

animación

el texto del LLM se escribe palabra por palabra mientras los valores de Jev ya aparecieron. Deja que termine: el contraste lo explica solo.

qué decir

- Contrasta los dos "terminales" en vivo: "Miren la diferencia. A la izquierda, el LLM te da una frase amable que igual tenés que interpretar. A la derecha, Jev te da la variable ya lista: equipo = billing, con 94% de probabilidad y 88% de confianza."
- Idea ancla: "Jev no produce algo para que lo leas tú; produce algo para que lo consuma tu código."

siguiente

05 · System 1 / System 2 (Kahneman)

System 1 / System 2 (Kahneman)

en pantalla

dos círculos, Jev en System 1.

qué decir

- Explica la metáfora si alguien no leyó a Kahneman: "System 1 es cuando ves $2+2$ y sabes que es 4 sin pensarlo. System 2 es cuando resuelves 38×41 : te toma esfuerzo."
- Remátalo: "Los LLMs viven en el System 2: deliberan, razonan, gastan. Jev es puro System 1: el reflejo. Por eso es su categoría propia, 'System One Model'."

siguiente

06 · Cómo funciona (arquitectura)

Cómo funciona (arquitectura)

en pantalla

diagrama State + preguntas → Parallel Sampler → outputs tipados. Menciona RLCD.

qué decir

- Recorre el diagrama de izquierda a derecha: "Le pasas un **state**, el contexto, y una lista de **preguntas tipadas**. Las resuelve todas de una y te devuelve valores listos."
- Destaca RLCD sin tecnicismo: "Y ojo con cómo lo entrenaron: no con feedback humano de '¿te gustó esta respuesta?', sino optimizando para que sus probabilidades sean **honestas**. Solo con datos sintéticos. Eso importa para el siguiente punto."

siguiente

07 · Autoregresivo vs paralelo

Autoregresivo vs paralelo

en pantalla

cadena de tokens vs 3 barras en paralelo. 70–500 ms vs 3–329 s.

animación

es una carrera. Jev termina casi al instante ("listo · 0.2 s") y el LLM sigue encendiendo tokens uno a uno. Si quieres repetirla mientras hablas, presiona R.

qué decir

- Explica el porqué de la velocidad: "Un LLM escribe una palabra, se relee entero, escribe la siguiente... cientos de veces. Es intrínsecamente secuencial. Jev no genera texto, así que puede resolver todo en paralelo, de una pasada."
- Aterriza el número: "Estamos hablando de milisegundos vs. segundos. No es 'un poco más rápido'. Es otra categoría."

siguiente

08 · Las 3 primitivas

Las 3 primitivas

en pantalla

Choice / Score / Noul con mini-gráficos.

qué decir

- Una frase por primitiva:
- **"Choice:** elige una opción de una lista. Clasificar, rutear."
- **"Score:** puntúa en una escala. Severidad, calidad, riesgo."
- **"Noul:** sí o no, pero te da la probabilidad. ¿Es phishing? 0.79."
- El punto arquitectónico (clave para devs): "Fíjense que la lógica de negocio queda en **nuestro** código, no enterrada en un prompt gigante. Es testeable, versionable, revisable en un PR."

siguiente

09 · Confianza calibrada / RLCD

Confianza calibrada / RLCD

en pantalla

curva de calibración, Jev sobre la diagonal, LLM sobre-confiado.

qué decir

- Explica el gráfico: "El eje X es la confianza que declara; el Y, cuánto acierta de verdad. Lo ideal es la diagonal: si dice 0.9, acierta 9 de 10."
- El contraste: "Los LLMs son fanfarrones/complacientes: te dicen 0.95 y aciertan 0.7. Jev está pegado a la diagonal. Eso te deja **usar la confianza como umbral de decisión**: algo que con un LLM no puedes hacer con seguridad."

siguiente

10 · Jev vs LLM (tabla)

Jev vs LLM (tabla)

en pantalla

tabla comparativa de 6 dimensiones.

qué decir

- No leas la tabla entera; señala 2–3 filas: "Miren output, latencia y costo. Ahí está toda la historia."
- Honestidad intelectual (suma credibilidad): "Y fíjense en 'contexto': 64K tokens. Es un límite real. Esto **no** reemplaza a un LLM; juega en otra liga."

siguiente

11 · La brecha, a escala

La brecha, a escala

en pantalla

barra sliver (Jev) vs barra larga (LLM), 193.6x / 444.6x.

qué decir

- Da el "para qué": "¿Por qué me importa 100 ms? Porque a esa velocidad podés meter IA **dentro de un loop en tiempo real**: un feed, una UI, mientras el usuario tipea, sin que note la espera. Eso antes no era posible con IA."
- Aviso de rigor: "Los benchmarks son de ellos, corridos en sus condiciones, y deben ser tomados como orden de magnitud"

siguiente 12 · Costos

Costos

en pantalla

\$0.042/MTok, output gratis, ejemplo \$4.20, demo 390x.

animación

el número grande baja desde \$10 (el techo de un LLM frontier) hasta \$0.042. Buen momento para quedarse callado un segundo.

qué decir

- Haz el cálculo tangible: "Cien mil clasificaciones por cuatro dólares con veinte. Piénsenlo para un job batch nuestro."
- La demo del builder ancla la comparación directa con un LLM top: "384 titulares por 19 centavos, ~390x más barato que Opus haciendo lo mismo."

siguiente

13 · Alucinaciones

Alucinaciones

en pantalla

"matemáticamente imposible" + el matiz type-safe ≠ correcto.

ritmo

al entrar solo se ve el claim. Primer → : aparece el asterisco y el panel del matiz. Segundo → : la conclusión sobre la confianza calibrada. Usa esas pausas para construir el remate.

qué decir

- Presenta el claim y luego el bisturí: "Dicen que alucinar es matemáticamente imposible. Y a nivel de **formato** es verdad: no puede devolver algo fuera de tu schema."
- El matiz que te hace ver crítico (no fan): "PERO, y esto es lo que quiero que se lleven, type-safe garantiza que la respuesta tenga **forma válida**, no que sea **correcta**. Un 'billing' equivocado de tu lista permitida sigue siendo un error. Pero al menos ahora, es un error bien tipado."
- Cierra con la salida práctica: "Por eso la confianza calibrada es la red: ponés un umbral y lo que caiga por debajo lo escalás a un humano o a un LLM."

siguiente

14 · Dónde destaca ✓

Dónde destaca ✓

en pantalla

clasificar/rutear, batch, tiempo real, guardrails, scoring.

qué decir

- Enmarca el patrón común: "Todos estos casos comparten una cosa: son **reglas de decisión difusas**, donde escribir if/else a mano sería frágil, pero no necesitas que la IA te explique nada."
- Menciona el uso de **guardrail** como el más subestimado: "Este me parece el más interesante para nosotros: usar Jev como portero barato para filtrar o verificar lo que produce un LLM."

siguiente

15 · Dónde NO ✕

Dónde NO ✕

en pantalla

escribir, razonar, contexto largo, conversar, bajo volumen, security.

qué decir

- Sé tajante (esto genera confianza): "Igual de importante es saber cuándo NO. Si necesitas que escriba, razone, compare fechas o mantenga una conversación: Jev no es la herramienta. Punto."
- La anécdota del bot de trading: "Al instante salieron muchos proyectos en el cual usaban Jev para operar en el mercado y no rindió. Moraleja: **rápido no es lo mismo que acertado**. Jev decide veloz, pero la calidad de la decisión depende del problema."

siguiente

16 · La regla mental

La regla mental

en pantalla

árbol "¿quién consume la salida?" → humano=LLM / software=Jev.

qué decir

- Regálales el criterio para llevarse: "Si se llevan una sola cosa, que sea esta pregunta: **¿la salida la lee un humano, o la consume otra pieza de software?** Humano → LLM. Software → Jev."
- Desactiva el falso dilema: "No es Jev **vs** LLM. Es Jev y LLM. Jev es el nervio reflejo; el LLM, la corteza que delibera. Se complementan."

siguiente

17 · Casos reales (apertura)

Casos reales (apertura)

en pantalla

5 tarjetas con los casos, cada una con su número clave.

qué decir

- "Todo lo que les conté es teoría. Pero ahora les voy a mostrar lo que la gente construyó con Jev en sus primeros días de vida."
- No expliques cada tarjeta aquí: es el mapa. Di que vas a pasar por los cinco.

siguiente

18 · Caso 1/5 · @nedwize, clasificador tributario

Caso 1/5 · @nedwize, clasificador tributario

en pantalla

tweet original + video. **Primer** → : el interruptor pasa de **en** a **es** y aparece la traducción.

qué decir

- Este es el que más nos toca: **clasificar documentos tributarios**, justo el tipo de trabajo que hacemos con la Carpeta Tributaria.
- El dato: 100% del corpus clasificado a \$0.001 por página, 34 veces más barato y 6 veces más rápido que su pipeline con LLM. Y es open source: se puede probar.

siguiente

19 · Caso 2/5 · @johnyeo_, router para agentes

Caso 2/5 · @johnyeo_, router para agentes

qué decir

- El patrón más reutilizable: **Jev delante de un agente como router**. Antes de que el agente lento piense, Jev elige skill, herramienta y parámetros.
- Resultado: agente 2 veces más rápido. Jev no reemplaza al LLM, le ahorra la parte de decidir

siguiente

20 · Caso 3/5 · @steventey, detección de abuso

Caso 3/5 · @steventey, detección de abuso

qué decir

- Dub (acortador de links) le pasó a Jev más de 10K dominios maliciosos conocidos y lo puso a marcar URLs sospechosas.
- Frase clave del tweet: "algo con lo que peleábamos desde el primer día, lo resolvimos en 2 horas".
Clasificación binaria clásica: un **Noul**.
- Ojo con el matiz del slide "Cuándo no": para seguridad, Jev es una **primera señal**, no la decisión final.

siguiente

21 · Caso 4/5 · @TheMattBerman, focus group sintético

Caso 4/5 . @TheMattBerman, focus group sintético

qué decir

- Lo más creativo: Jev "mira" 723 anuncios como si fuera 30 tipos de comprador distintos y decide si parar o seguir scrolleando.
- 21.690 decisiones por 22 centavos. Muestra la escala: juicios masivos en paralelo que con un LLM serían carísimos.

siguiente

22 · Caso 5/5 · @fazlerocks, ad blocker en vivo

Caso 5/5 - @fazlerocks, ad blocker en vivo

qué decir

- Tiempo real en el navegador: mira cada elemento de la página y decide "anuncio o no", sin listas de filtros.
- 16 anuncios fuera de un artículo por \$0.0008, y queda en caché. Es el ejemplo perfecto de los 100 ms: ¡A dentro de la UI sin que se note.
- Cierre de la sección: "Clasificar, rutear, detectar, simular, filtrar. Cinco verbos, un mismo modelo."

Tip videos: arrancan solos y en silencio al entrar al slide. Clic sobre el video lo pausa o reanuda. **M** activa o quita el audio.

siguiente

23 · OpenAI responde: Decisions API

OpenAI responde: Decisions API

en pantalla

fondo oscuro, línea de tiempo 15:09 → 29:09, el request/response del endpoint y ~150 ms.

animación

la línea de tiempo se dibuja y el contador baja de 1600 a ~150 ms. El dark marca que salimos de Jev y entramos a la competencia.

qué decir

- El giro: "Y esto es lo que me terminó de convencer de que Jev no es una moda. Dos semanas después, en el DevDay del 29 de septiembre, OpenAI sacó su propia versión: **Decisions API**."
- Qué es: "Una pregunta, una lista cerrada de respuestas y un contexto, texto o imagen. Te devuelve una de esas respuestas. La idea de Jev."
- Velocidad: "OpenAI dice unos 150 ms, contra 1.6 s de una llamada normal a GPT-6 Luna, el modelo que corre debajo."
- La lectura: "Cuando OpenAI copia una categoría en dos semanas, la categoría es real."

siguiente

24 · Jev vs Decisions API

Jev vs Decisions API

en pantalla

tabla de 6 filas (estado, motor, input, output, latencia, precio). **Primer** → : aparece el gráfico de calibración (Jev 98.9% vs Luna 68%) y la frase de cierre.

qué decir

- Sé justo con OpenAI, suma credibilidad: "Tiene cosas a favor: acepta imágenes, cosa que Jev no, y viene con todo el ecosistema de OpenAI detrás."
- La letra chica: "Pero hoy es preview limitada, no tiene precio publicado ni documentación del endpoint. Y lo más importante: no es un modelo nuevo, es un LLM, Luna, con una API encima."
- → y el remate: "Un test independiente de Anthus midió esto: cuando Luna dice estar 99% segura, acierta 68%. Jev, 98.9%. La velocidad se copió en dos semanas. La calibración, no."
- Conecta con el slide 09: "Y sin una confianza en la que se pueda confiar, no puedes poner umbrales. Vuelves a tratar cada respuesta como sospechosa."

siguiente

25 · Resumen (TL;DR)

Resumen (TL;DR)

en pantalla

la frase resumen + chips.

qué decir

- Repite la tesis una vez más, lento: "Jev cambia conversación por decisión: tipada, calibrada, cien veces más rápida y barata. Brillante para clasificar y rutear; inútil para escribir. Es un modelo **nuevo**, no un LLM mejor."

siguiente

26 · Gracias

Gracias

qué decir

- "Gracias. Abro preguntas, y si quieren pasamos a ver los casos de Sheriff en detalle."

Notas de rigor (por si preguntan)

- **Fuentes:** TypeSafe AI (blog oficial), Wikipedia "Jev (AI model)", Requesty, MindStudio, LangChain, Towards Data Science. Consultadas 24-09-2026.
- **Sesgo de benchmarks:** los números de velocidad/costo son de TypeSafe, corridos en sus condiciones (laptops en la costa oeste, comparando contra competidores). Preséntalos como órdenes de magnitud.
- **Dato honesto a mano:** 64K de contexto y la distinción "type-safe ≠ correcto" son los dos límites que te blindan de sonar como vendedor.
- **Si preguntan por disponibilidad:** early access limitado desde el 15-09-2026, abierto a todos desde el 27-09-2026.
- **Decisions API (OpenAI):** anunciada en DevDay el 29-09-2026, corre sobre GPT-6 Luna, preview limitada. Endpoint `POST /v1/decisions`; con API keys normales hoy responde 403. Fuentes: OpenAI DevDay recap, The New Stack, eesel AI, OrcaRouter, Hugging Face blog, Anthus. Consultadas 02-10-2026.
- **Precio de Decisions API:** la mayoría de las fuentes dice que **no está publicado**; algún blog repite el \$0.042 de Jev, pero no lo confirma OpenAI. Si preguntan: "sin precio oficial todavía".
- **¿Devuelve confianza?** Hay un score según la prensa, pero OpenAI no documenta que sea calibrado. Por eso en el slide dice "un score" y el request/response está marcado como ilustrativo.
- **Test de Anthus:** midió GPT-6 Luna (el modelo base), no el endpoint de Decisions API. A 99% de confianza declarada, Luna acertó 68% y Jev 98.9%; error de calibración 0.32 vs 0.03–0.04. Es un tercero, no OpenAI ni TypeSafe: preséntalo así.